Analyse de la variance (anova)

quantitatif ~ f (qualitatif)

Benjamin Louis

16/10/2019 (MàJ: 18/11/2021)

Définition et objetif

Modèle général :

$$y_{ij...nr} = \mu + lpha_i + eta_j + \ldots + \gamma_n + \ldots + lphaeta_{ij} + \ldots + eta\gamma_{jn} + \epsilon_{ij...nr}$$
 $\epsilon_{ij...nr} o N(0, \sigma^2) \quad cov(\epsilon_{ij...nr}, \epsilon_{i'j'...n'r'}) = 0$

- μ : intercept
- α , β , γ : variables qualitatives
- ullet $lpha_i$: valeur pour la modalité i de la variable associée au paramètre lpha
- $\alpha\beta$: interaction entre α et β
- ϵ : erreur résiduelle

Objectif principal:

Tester et étudier l'influence de variables qualitatives sur une variable numérique.

Hypothèses:

- Sur les résidus
- Sur les coefficients : $lpha_{ref}=0$ ou $\sum_i lpha_i=0$

Exemple

- Expérimentation en plein champ avec I = 3 variétés différentes de blé et J
 = 2 types de fongicides
- 54 parcelles : 9 répétitions pour chaque pair de variété et fongicide
- Question : existe t-il des différences de rendement entre les variétés de blé et selon le fongicide utilisé ?
- Model:

$$rendement_{ijr} = \mu + \alpha_{variete=i} + \beta_{fongicide=j} + \alpha\beta_{variete=i,fongicide=j} + \epsilon_{ijr}$$

Estimation par moindres carrés (modèle à 1 facteur!)

```
# Par défaut dans R
#
#
```

- $\hat{\mu} = ar{y}_{i=ref}$
- $egin{aligned} &\hat{lpha}_{i=ref}=0\ &\hat{lpha}_{i
 eq ref}=ar{y}_{i
 eq ref}-\mu \end{aligned}$

- $\hat{\mu} = \bar{y}$
- $\hat{lpha}_i = ar{y}_i \mu$

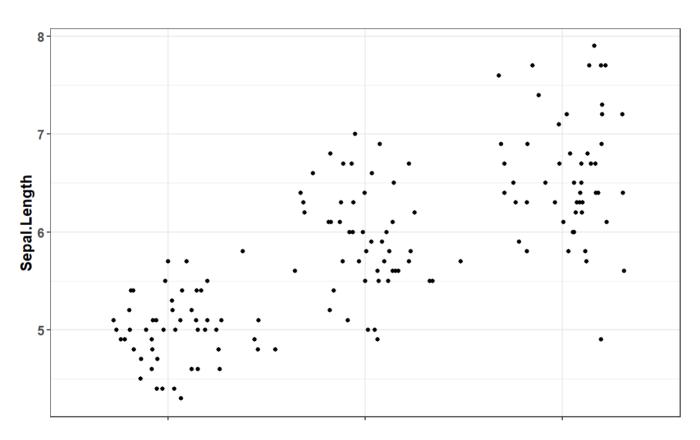
•
$$\hat{y}_{ik} = \hat{\mu} + \hat{\alpha}_i$$


$$\bullet \ e_{ik} = y_{ik} - \hat{y}_{ik}$$


•
$$\hat{\sigma}^2 = rac{\sum_{ik} \epsilon_{ik}^2}{n-I}$$


•
$$\hat{\sigma}_{\hat{lpha}_i}^2 = rac{I-1}{n}\hat{\sigma}^2$$

Sepal.Length_{ik}









Test de l'effet d'une variable

• La variabilité de *y* entre les modalités de la variable est elle *significativement* plus grande que la variabilté résiduelle ?

🛕 Dans le cas d'un plan équilibré 🛕 :

$$\sum_{ij} \left(y_{ij} - \bar{y}\right)^2 = \frac{n}{I} \sum_{i} \left(\hat{\alpha}_i\right)^2 + \sum_{ij} \left(e_{ij}\right)^2$$

Variabilité totale = Variabilité interclasse + Variabilité interclasse (between group) + SSR + SSR

Test : à quel point SS_F est plus grande que SS_R ? (Plus il y a de groupes/observations, plus les valeurs risques d'être élevées !)

$$CM_F = rac{SS_F}{I-1} \hspace{1cm} CM_R = rac{SS_R}{n-(I-1)-1}$$

Dans R

Test de l'effet d'une variable

Hypothèse:

 H_0 : $\alpha_i = 0, \ \ \forall \ \ i$, tous les coefficients sont égaux, donc nuls

 $H_1: \exists \ \alpha_i \neq 0$, un coefficient au moins n'est pas nul


Statistique de test :

$$F_{obs} = rac{CM_F}{CM_R}$$

Sous H_0 :

$$F_{obs} o F_{n-I}^{I-1}$$

Test de l'effet d'une variable



Dans R

```
options(contrasts=c("contr.sum","contr.sum"))
mod = lm(Sepal.Length ~ Species, data = iris)
anova(mod)
## Analysis of Variance Table
##
## Response: Sepal.Length
##
       Df Sum Sq Mean Sq F value Pr(>F)
## Species 2 63.212 31.606 119.26 < 2.2e-16 ***
## Residuals 147 38.956 0.265
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
pf(119.26, 2, 147, lower.tail = FALSE)
```

Exemples avec plus de facteurs

```
library(agricolae)
data(greenhouse)
data <- greenhouse$greenhouse1</pre>
mod <- lm(weight ~ variety*method, data = data)</pre>
anova(mod)
## Analysis of Variance Table
##
## Response: weight
##
                  Df Sum Sq Mean Sq F value Pr(>F)
## variety 2
                      2297
                              1148 0.7279 0.4835
## method
              3 483322 161107 102.1204 <2e-16 ***
## variety:method 6 150619 25103 15.9120 <2e-16 ***
## Residuals 468 738326 1578
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
```

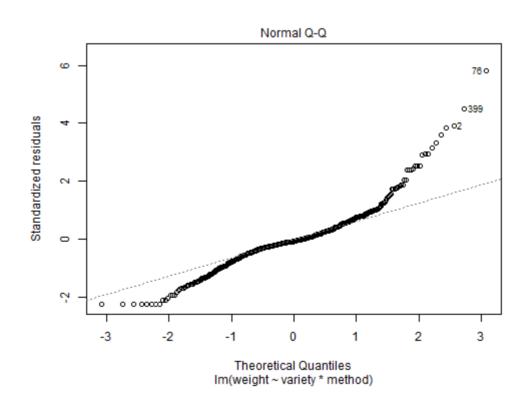
Summary

Énormément d'information donné par le summary () !!!


summary(mod)

```
##
## Call:
## lm(formula = weight ~ variety * method, data = data)
##
## Residuals:
      Min
               10 Median
                               30
                                      Max
## -88.547 -17.871 -3.492 15.626 227.944
## Coefficients:
                   Estimate Std. Error t value Pr(>|t|)
##
## (Intercept)
                     72.664
                                 1.813 40.081 < 2e-16 ***
## varietv1
                      1.056
                                 2.564
                                       0.412 0.68067
                                 2.564 0.776 0.43799
## varietv2
                      1.990
## method1
                      2.022
                                 3.140 0.644 0.51996
## method2
                     11.814
                                 3.140
                                         3.762 0.00019 ***
## method3
                    -50.440
                                 3.140 -16.063 < 2e-16 ***
## variety1:method1
                    -35.589
                                 4.441 -8.014 8.92e-15 ***
## variety2:method1
                     18.681
                                 4.441 4.207 3.11e-05 ***
                                 4.441 0.454 0.65035
## varietv1:method2
                     2.014
## variety2:method2
                                 4.441 2.327 0.02038 *
                     10.335
## variety1:method3
                     2.855
                                         0.643 0.52054
                                 4.441
## variety2:method3
                     -9.963
                                 4.441 -2.243 0.02533 *
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 39.72 on 468 degrees of freedom
## Multiple R-squared: 0.4629,
                                 Adjusted R-squared: 0.4502
## F-statistic: 36.66 on 11 and 468 DF, p-value: < 2.2e-16
```


plot(mod, which = 2)




plot(mod, which = 1)



```
qplot(x = data$variety, y = residuals(mod), geom = "point")
```



```
qplot(x = data$method, y = residuals(mod), geom = "point")
```



Tests post-hoc (comparaisons multiples)

```
library(emmeans)
pairs(emmeans(mod, ~method))
## NOTE: Results may be misleading due to involvement in interactions
                        estimate SE df t.ratio p.value
##
   contrast
                      -9.79 5.13 468 -1.910 0.2253
##
   aeroponic - bed
##
   aeroponic - hydroponic 52.46 5.13 468 10.231 <.0001
##
   aeroponic - pot -34.58 5.13 468 -6.744 <.0001
   bed - hydroponic 62.25 5.13 468 12.141 <.0001
##
   bed - pot
                  -24.79 5.13 468 -4.834 <.0001
##
   hydroponic - pot
##
                          -87.04 5.13 468 -16.975 <.0001
##
## Results are averaged over the levels of: variety
## P value adjustment: tukey method for comparing a family of 4 estimates
```

Tests post-hoc (comparaisons multiples)

pairs(emmeans(mod, ~variety|method))

```
## method = aeroponic:
## contrast
                    estimate SE df t.ratio p.value
## Costanera - Mariya -55.20 8.88 468 -6.216 <.0001
## Costanera - Unica -48.40 8.88 468 -5.449 <.0001
## Mariva - Unica 6.81 8.88 468 0.767 0.7237
##
## method = bed:
                             SE df t.ratio p.value
## contrast
                estimate
## Costanera - Mariva
                       -9.26 8.88 468 -1.042 0.5507
## Costanera - Unica
                      18.46 8.88 468 2.079 0.0953
                   27.72 8.88 468 3.121 0.0054
## Mariva - Unica
##
## method = hydroponic:
                              SE df t.ratio p.value
## contrast
                    estimate
## Costanera - Mariva 11.88 8.88 468 1.338 0.3748
## Costanera - Unica -0.15 8.88 468 -0.017 0.9998
## Mariva - Unica -12.03 8.88 468 -1.355 0.3656
##
## method = pot:
                              SE df t.ratio p.value
## contrast
                 estimate
## Costanera - Mariva 48.84 8.88 468 5.499 <.0001
## Costanera - Unica 46.49 8.88 468 5.234 <.0001
## Mariva - Unica
                    -2.35 8.88 468 -0.265 0.9621
##
## P value adjustment: tukey method for comparing a family of 3 estimates
```



Tableau d'Anova

| | fongicide | variete | interaction |
|---------|-----------|-----------|-------------|
| p-value | 0.0500205 | 0.0006926 | 0.231347 |

Comparaisons fongicides

| | Estimate | p-value |
|-------|----------|-----------|
| F1-F2 | 9.81 | 0.0500205 |

Comparaisons variétés

| | Estimate | p-value |
|-------|----------|-----------|
| V1-V2 | 2.58 | 0.0284387 |
| V1-V3 | 3.36 | 0.0173694 |
| V2-V3 | 0.78 | 0.1120579 |

Quelles conclusions peut-on faire de ces résultats ?

p-value !!!

- Les *p-value* dépendent de la qualité ET de la quantité des données !
- Le seuil de 0.05 est arbitraire!
- Les résultats des tests statistiques ne sont pas la fin de l'analyse. Il est important de prendre du recul et d'évaluer la qualité des résultats !
- Les résultats des tests ne consituent pas des conclusions/décisions ! Ce sont des outils qui aident les experts à conclure/décider !

Exercice 2


Analyse du fichier *cow.csv*: mesure de rendement de production laitière par différentes vaches. Les vaches ont reçu soit la ration R1, soit la ration R2 de nourriture et sont à des âges différents (1ère, 2ème, 3ème ou 4ème lactation).

Existe t-il une influence de la ration et/ou de la lactation sur la production de lait ?

```
library(readr)
library(ggplot2)
library(emmeans)
library(dplyr)
data <- read_delim(here::here("static/data/cows.csv"), delim = ";")
summary(data)</pre>
```

```
lactation
##
      ration
                                           vield
   Length:32
                 Length:32
                                       Min.
##
                                             :2660
   Class :character Class :character
##
                                       1st Qu.:3470
   Mode :character Mode :character
                                       Median: 3716
##
##
                                       Mean :3738
##
                                       3rd Qu.:4030
                                       Max.
##
                                             :4792
```

```
ggplot(data) +
  aes(x = lactation, y = yield, color = ration) +
geom_point()
```




mod <- lm(yield ~ ration + lactation + ration:lactation, data = data)
anova(mod)</pre>


summary(mod)

```
##
## Call:
## lm(formula = yield ~ ration + lactation + ration:lactation, data = data)
##
## Residuals:
             10 Median
     Min
                          30
                                Max
                0.5 142.8 456.0
## -471.0 -133.0
##
## Coefficients:
                    Estimate Std. Error t value Pr(>|t|)
##
## (Intercept)
                     3737.63
                                 43.76 85.411 < 2e-16 ***
## ration1
                                        2.705 0.012362 *
                     118.37
                              43.76
                             75.80 -4.111 0.000397 ***
## lactation1
                     -311.63
## lactation2
                     -317.62
                                75.80 -4.191 0.000325 ***
                    484.87 75.80 6.397 1.29e-06 ***
## lactation3
## ration1:lactation1 176.62
                             75.80 2.330 0.028525 *
## ration1:lactation2 69.63 75.80 0.919 0.367450
                                75.80 -3.455 0.002059 **
## ration1:lactation3 -261.88
## ---
## Signif. codes: 0 '*** 0.001 '** 0.01 '* 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 247.5 on 24 degrees of freedom
## Multiple R-squared: 0.7698, Adjusted R-squared: 0.7027
## F-statistic: 11.47 on 7 and 24 DF, p-value: 2.562e-06
```


plot(mod, which = 2)




```
qplot(x = data$ration,
    y = residuals(mod),
    geom = "point")
```



plot(mod, which = 1)



```
qplot(x = data$lactation,
    y = residuals(mod),
    geom = "point")
```



```
library(emmeans)
pairs(emmeans(mod,~ration))
## NOTE: Results may be misleading due to involvement in interactions
   contrast estimate SE df t.ratio p.value
   R1 - R2
                 237 87.5 24 2.705
                                    0.0124
##
## Results are averaged over the levels of: lactation
pairs(emmeans(mod,~lactation))
## NOTE: Results may be misleading due to involvement in interactions
   contrast estimate SE df t.ratio p.value
   A - B
                   6 124 24 0.048 1.0000
             -796 124 24 -6.435 <.0001
   A - C
   A - D
              -456 124 24 -3.684 0.0060
           -802 124 24 -6.484 <.0001
   B - C
   B - D
           -462 124 24 -3.733 0.0053
                340 124 24 2.751 0.0508
   C - D
## Results are averaged over the levels of: ration
```

P value adjustment: tukey method for comparing a family of 4 estimates

pairs(emmeans(mod,~ration|lactation))

pairs(emmeans(mod,~lactation|ration))

```
## ration = R1:
## contrast estimate SE df t.ratio p.value
   A - B
               113 175 24 0.646 0.9161
##
   A - C
              -358 175 24 -2.045 0.1999
##
   A - D
              -295 175 24 -1.685 0.3530
              -471 175 24 -2.691 0.0577
## B - C
          -408 175 24 -2.331 0.1190
  B - D
              63 175 24 0.360 0.9836
## C - D
##
## ration = R2:
   contrast estimate SE df t.ratio p.value
              -101 175 24 -0.577 0.9380
          -1235 175 24 -7.055 <.0001
   A - C
              -617 175 24 -3.525 0.0088
           -1134 175 24 -6.478 <.0001
   B - C
           -516 175 24 -2.948 0.0331
   B - D
              618 175 24 3.531 0.0087
##
   C - D
##
## P value adjustment: tukey method for comparing a family of 4 estimates
```